WEEK 04

기술통계 기초

평균·중앙값·분산·표준편차, 분포의 이해

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

오늘의 질문

4,900만원.
두 회사의 평균 연봉이 똑같습니다.

한 곳은 20명 중 17명이 평균 이하입니다.
다른 곳은 거의 전원이 평균 근처입니다.

같은 숫자인데, 어디서 갈렸을까요?

오늘 도착할 곳

세 가지를 가져갑니다

1 기술

평균·중앙값·분산·표준편차가 **각각 무엇을 재는 숫자인지** 안다.

2 판단

상황에 따라 **어떤 대푯값을 보고할지** 고르고, 그 이유를 말한다.

3 함정

AI에게 요약을 시키면 **무조건 평균부터** 들이민다.

PART I · 60분

숫자 몇 개로 수천 개를 대신하기

기술통계(descriptive statistics)는 요약이다. 요약에는 반드시 **버려지는 것**이 있다. 무엇이 버려지는지 아는 것이 오늘의 일이다.

대푯값 · 1 ★

맨 앞 질문의 답



«우리 회사 평균 연봉은 4,900만원입니다» — 거짓말이 아니다. 다만 그 근처에 있는 사람이 아무도 없다.

평균은 값 하나하나를 다 더한다. 그래서 아주 큰 값 하나에 통째로 끌려간다. 중앙값은 «줄을 세웠을 때 한가운데 사람» 이라 끌려가지 않는다.

대푯값 · 2

평균이 하는 일과 못 하는 일

평균이 잘하는 것

모든 값을 **하나도 빠뜨리지 않고** 반영한다.
전체를 더한 뒤 나누는 것이라 **총량**과 직결된다.
계산이 쉽고, 이후의 거의 모든 통계가 평균 위에 세워진다.

평균이 못하는 것

모든 값을 반영하기 때문에 **극단값 하나에 통째로 끌려간다**.
«가운데»가 아니라 **무게중심**이다.
평균 위치에 실제로 사람이 있는지는 알려주지 않는다.

> 평균은 **시소의 받침점**입니다. 끝에 앉은 한 사람이 무거우면 받침점은 그쪽으로 옮겨갑니다. 나머지 사람이 몇 명이든 상관없이.

대푯값 · 3

중앙값과 최빈값

대푯값	정의	극단값에	이럴 때 쓴다
평균 mean	다 더해서 개수로 나눈다	끌려간다	좌우가 대칭이고 극단값이 없을 때
중앙값 median	줄을 세웠을 때 한가운데 값	버틴다	연봉·집값·대기시간처럼 한쪽이 늘어질 때
최빈값 mode	가장 자주 나온 값	버틴다	색깔·학과처럼 숫자가 아닌 항목

중앙값은 **순서만** 봅니다. 맨 오른쪽 사람의 연봉이 3억이든 300억이든 한가운데 사람은 그대로입니다. 이것이 «버틴다»의 뜻입니다.

대푯값 · 4 ★

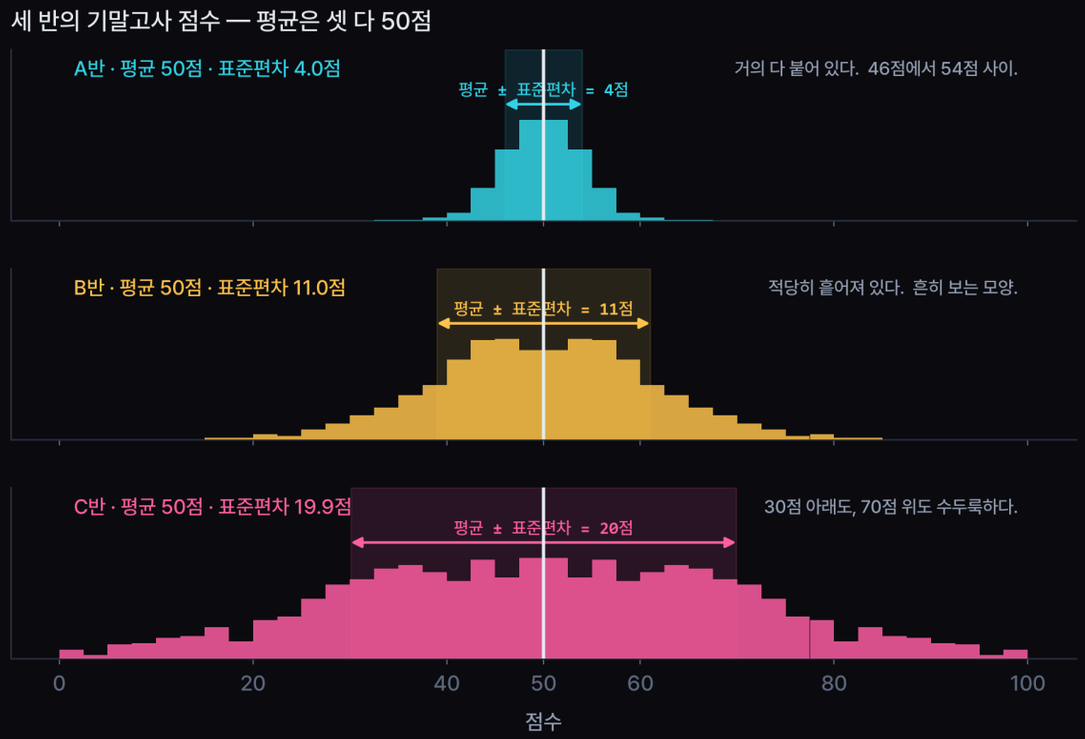
직접 밀어보세요 — 무엇이 끌려가고 무엇이 버티는가

인터랙티브 데모

이 자리에는 직접 조작하는 3D 데모가 있습니다.
HTML 슬라이드를 브라우저로 열어 확인하세요.

흩어짐 · 1 ★

평균이 같아도 같은 데이터가 아니다



평균 50점. 세 반에 같은 보충수업을 처방하겠는가?

3주차에 «평균은 지켜지고 표준편차만 줄었다» 고 했던 말이 바로 이 그림이다. 가운데가 같아도 흩어진 정도가 다르면 다른 데이터다.

흘어짐 · 2 ★

지난주 그 말의 뜻

3주차에 이렇게 말했습니다 —

«평균으로 빈칸을 채우면 평균은 그대로인데 표준편차만 줄어든다»

그때는 이렇게 들렸다

숫자 하나가 조금 작아지는 일. 평균이 안 변하니 별문제 아닌 것.

지금은 이 뜻이다

빈칸을 전부 **평균 자리**에 놓았다는 것은, 편차가 **정확히 0**인 가짜 데이터를 대량으로 끼워넣었다는 뜻이다.

C반이 A반처럼 보이게 된다.

데이터가 실제보다 **고르다**고 주장하는 것입니다. 없는 안정성을 만들어낸 것이고, 11주차에서는 이것이 **없는 차이를 «유의하다»**고 말하게 만듭니다.

흩어짐 · 3 ★

흩어진 정도를 재는 법

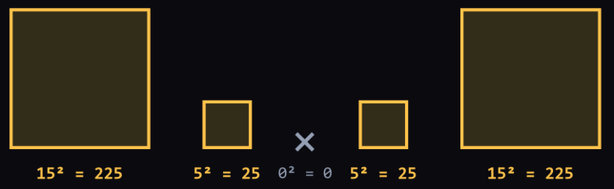
다섯 명의 점수 60 · 70 · 75 · 80 · 90



① 각 값에서 평균을 뺀다 — 이것이 «편차».
그런데 그냥 더하면 (-15) + (-5) + 0 + 5 + 15 = 0. 왼쪽과 오른쪽이 서로를 지운다.
부호를 그대로 두면 «흩어진 정도» 를 잴 수 없다. 그래서 다음 수가 필요하다.

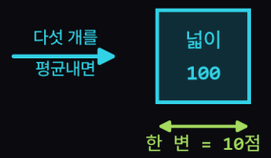
② 제곱한다 — 편차를 한 변으로 하는 정사각형

225 + 25 + 0 + 25 + 225 = 500



③ 평균낸다 = 분산

500 ÷ 5 = 100 점²



④ 제곱근을 씌운다 √100 = 10

왜 제곱하는가

부호가 사라진다. 덤으로 멀리 있는 값일수록 훨씬 크게 반영된다 — 넓이가 곧 벌점이다.

왜 다시 제곱근을 씌우는가

분산의 단위는 «점²» 이다. 점의 제곱이 무엇인지 설명할 길이 없다. 제곱근을 씌워야 «점» 으로 돌아오고, 그제서야 사람 말이 된다.

표준편차 10점 = «다들 평균 75점에서 대체로 10점쯤 떨어져 있다»

분산 = 편차²의 평균 · 표준편차 = √분산. 외울 것은 이 두 줄이고, 뜻은 «평균에서 얼마나 떨어져 있나» 하나다.

흩어짐 · 4

표준편차를 사람 말로 읽기

평균 75점, 표준편차 10점

→ «다들 75점에서 대체로 10점쯤 떨어져 있다»

평균 75점, 표준편차 2점

→ «거의 다 73~77점에 몰려 있다»

단위가 중요하다

표준편차는 원래 단위 그대로다 — **점, 원, 분**.
그래서 평균과 나란히 놓고 읽을 수 있다.
분산은 **점²**이라 읽을 수가 없다. 계산 도중에만 쓴다.

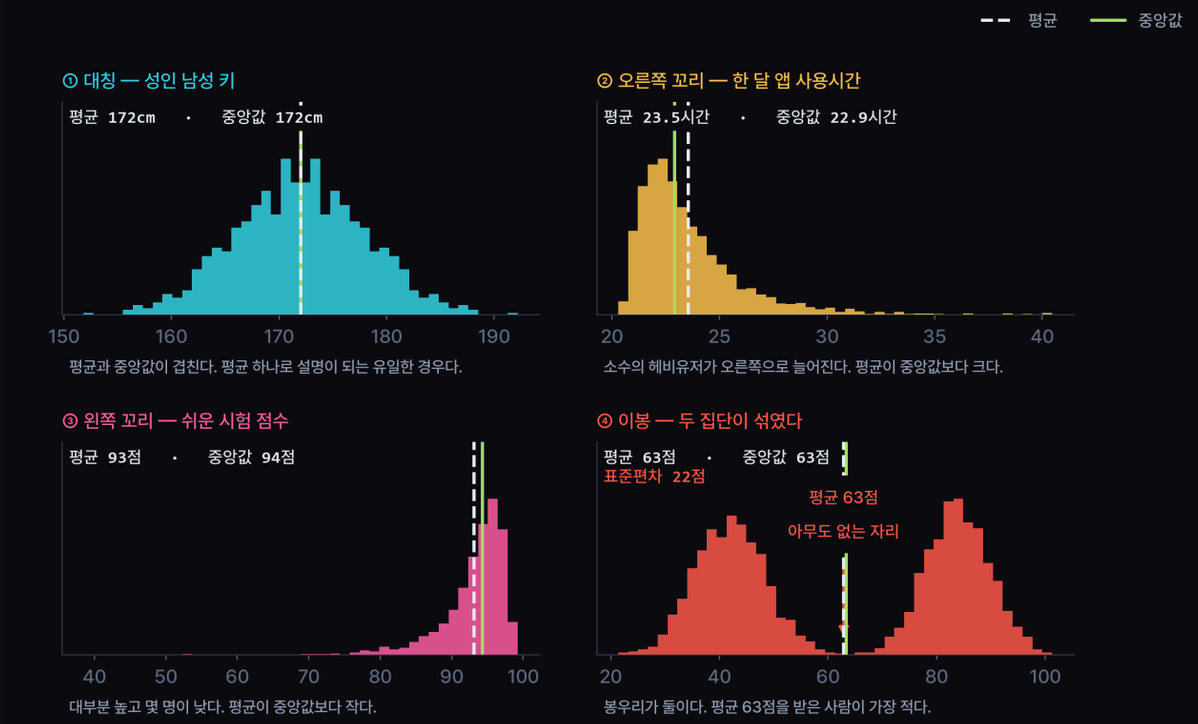
보고할 때는 한 쌍으로

평균 하나만 쓴 보고서는 미완성이다.
평균 옆에는 반드시 흩어짐이 붙어야 한다.

평균 75점 (표준편차 10점, n=32)

분포 · 1 ★

분포의 모양 네 가지



평균과 중앙값이 겹친다. 평균 하나로 설명이 되는 유일한 경우다.

소수의 헤비유저가 오른쪽으로 늘어진다. 평균이 중앙값보다 크다.

대부분 높고 몇 명이 낮다. 평균이 중앙값보다 작다.

봉우리가 둘이다. 평균 63점을 받은 사람이 가장 적다.

④에서 «평균 63점 · 표준편차 22점» 두 숫자 중 어느 것도 «40점대 무리와 80점대 무리» 라는 사실을 알려주지 않는다.

3주차의 표준편차도 그렇다. 숫자는 모양을 대신하지 못한다. 그려 봐야 안다.

분포 · 2

이봉 분포 — 평균이 빈자리를 가리킨다

봉우리가 둘이면

40점대 무리와 80점대 무리가 섞여 있다.
평균은 **63점**. 그런데 63점을 받은 사람이 **가장 적다**.
평균이 **아무도 없는 자리**를 가리킨다.

봉우리가 둘이라는 것은 대개 **다른 두 집단이 한 표에 섞여 있다**는 신호입니다.
요약할 것이 아니라 **쪼개야** 합니다.

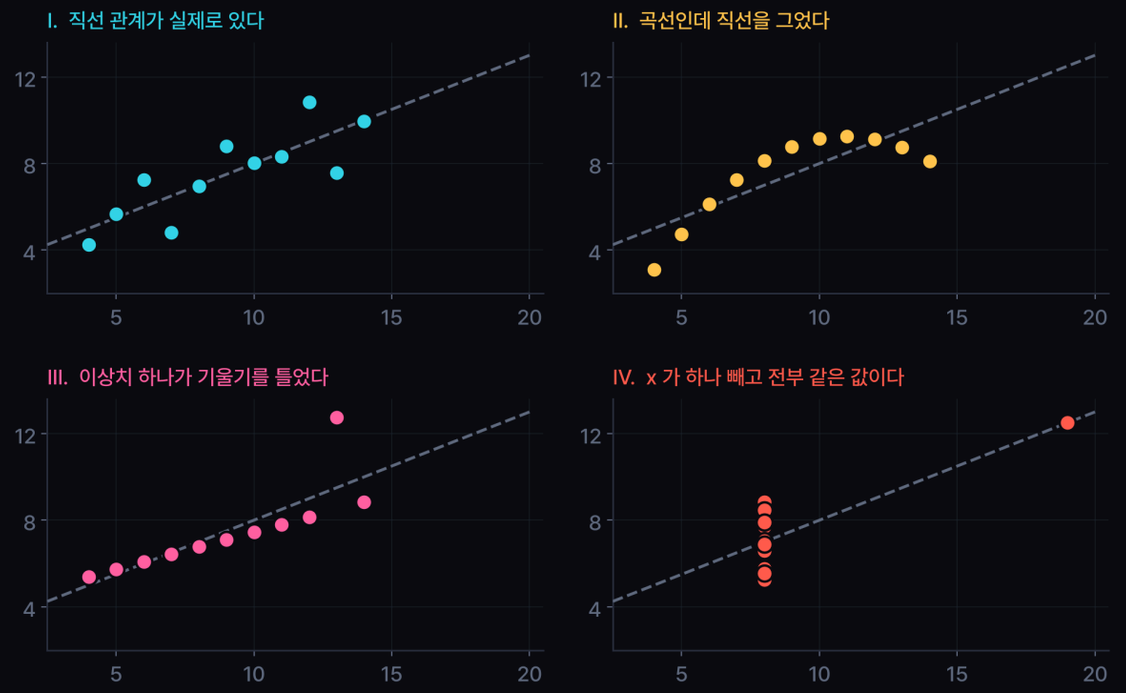
현실의 예

- 수강생 점수 — 재수강생과 신규 수강생
- 앱 체류시간 — 무료 사용자와 유료 사용자
- 통학시간 — 자취생과 통학생
- 매출 — 평일과 주말

섞인 두 집단을 갈라놓을 **기준 변수**를 찾는 일이 7주차 상관·교차분석으로 이어집니다.

분포 · 3 ★

앤스컴 4중주



x 평균 9.0 · y 평균 7.5 · x 분산 11.0 · y 분산 4.1 · 상관계수 0.82 · 회귀직선 y = 3.00 + 0.50x

네 데이터의 위 여섯 숫자가 모두 같다. 소수점을 더 내려가도 셋째 자리에서야 갈린다.

숫자가 같다고 데이터가 같은 것이 아니다. 그려 보기 전에는 모른다.

PART II · 30분

어떤 숫자를 보고할 것인가

평균을 쓸지 중앙값을 쓸지는 계산 문제가 아니다.
무엇을 말하려는가에 달린 판단이다.

판단 · 1

결정표

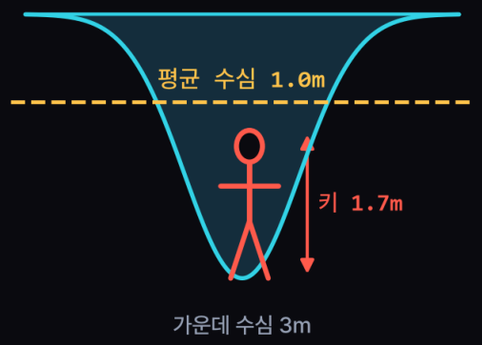
상황	보고할 것	이유
신입 연봉이 얼마인지 알고 싶다	**중앙값**	임원 몇 명이 평균을 끌어올린다
인건비 예산을 짜야 한다	**평균**	총액이 필요하다. 평균×인원 = 총액
배달이 보통 얼마나 걸리나	**중앙값**	사고 한 건이 2시간이면 평균이 망가진다
두 반의 성적을 비교한다	**평균 + 표준편차**	가운데가 같아도 다른 반일 수 있다
설문 만족도를 요약한다	**분포 전체**	평균 3.0점이 «보통»을 뜻하지 않는다

> **규칙 하나만 외운다면:** 평균과 중앙값을 **둘 다 계산해 보고**, 많이 다르면 그 차이 자체가 보고할 내용입니다.

판 단 · 2 ★

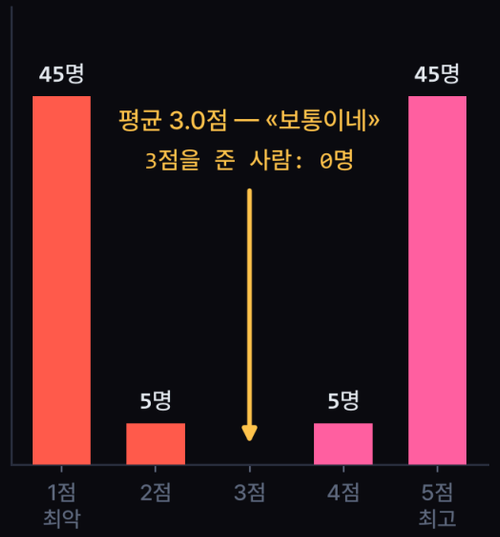
평균의 함정 — 실제로 벌어지는 일

① 평균 수심 1m 인 강



평균은 참이다. 그리고 사람이 빠져 죽는다.

② 만족도 평균 3.0점



칭찬과 분노가 반씩이다. 평균은 그것을 지운다.

③ 표본이 작을 때



별점 4.7(3명) 과 4.7(3,000명) 은

같은 숫자가 아니다.

한 사람이 평균을 통째로 옮긴다.

평균은 요약이지 설명이 아니다.

요약을 믿기 전에 세 가지를 먼저 묻는다 — 얼마나 흩어져 있나 · 모양이 어떤가 · 몇 명한테 물었나.

판단 · 3

평균을 보면 세 가지를 묻는다

1 얼마나 흩어졌나

표준편차가 붙어 있지 않은 평균은 절반만 말한 것이다.

2 모양이 어떤가

봉우리가 하나인가 둘인가. 한쪽으로 늘어졌는가.

3 몇 명한테 물었나

4.7점(3명)과 4.7점(3,000명)은 같은 숫자가 아니다.

이 세 질문은 **남의 보고서를 볼 때**도, **내 보고서를 쓸 때**도 똑같이 씁니다. 셋 중 하나라도 답이 없으면 그 평균은 아직 읽을 수 없는 숫자입니다.

판단 · 4

오늘의 한 문장

> **숫자가 같다고 데이터가 같은 것이 아니다.**
> **그려 보기 전에는 모른다.**

앤스컴의 네 데이터는 평균·분산·상관계수·회귀직선이 모두 같았습니다. 그래도 전혀 다른 데이터였습니다. **그림 한 장**이 그것을 1초 만에 밝혀냈습니다.

그래서 실습의 검증 조건에는 언제나 «그려서 보여줄 것»이 들어갑니다.

PART III · 50분

바이브코딩 실습

AI에게 요약을 시키되, **평균 하나로 끝내지 못하게** 만든다.

AI 함정 #3

AI는 무조건 평균부터 말한다

이렇게 물어보면

"이 데이터 요약해줘"

↓ 어떤 데이터를 줘도 돌아오는 답

- 평균 63.4
- 최댓값 92, 최솟값 31
- 행 480개, 열 7개
- "전반적으로 중간 수준입니다"

치우쳐 있어도 · 봉우리가 둘이어도
이상치가 있어도 같은 답

이렇게 물어야 한다

"평균과 중앙값을 같이 보고하고,
두 값이 다르면 왜 다른지 설명해줘.
그리고 히스토그램을 그려줘."

↓ 그러면 드러나는 것

- 꼬리가 어느 쪽으로 늘어졌는지
- 봉우리가 몇 개인지
- 이상치가 있는지
- 평균이 대표값 노릇을 하는지

실습 · 1

이번 주 명세

```
[목표]
내 데이터의 숫자 열 하나를 «기술통계로 요약» 하고,
평균 하나로 요약해도 되는 열인지 판정한다.

[제약]
- 결측치를 평균으로 채우지 말 것. 뺀 행 수를 밝힐 것
- 이상치를 임의로 지우지 말 것
- 그래프 색은 지정하지 말고 기본값으로 둘 것

[검증 조건]
- 평균과 중앙값을 «함께» 보고할 것. 둘의 차이도 같이 적을 것
- 표준편차와 함께 n(사용한 행 수) 을 반드시 적을 것
- 분포를 «반드시 그릴 것» — 히스토그램, 구간 20개 이상
- 최솟값·최댓값과 그 값을 가진 행을 같이 보여줄 것
- 마지막 줄에 한 문장으로 답할 것:
  «이 열은 평균으로 요약해도 되는가 / 안 되는가 · 그 이유»

[비목표]
- 상관, 예측, 통계적 검정
- 예쁜 그래프 꾸미기
```

> [검증 조건]의 셋째 줄이 오늘의 핵심입니다. **그리라고 시키지 않으면 AI는 그리지 않습니다.** 그리고 그리지 않으면 아무도 모릅니다.

실습 · 2

오늘 할 것 — 50분

#	할 일	확인할 것
1	먼저 **"이 데이터 요약해줘"** 한 줄만 넣어본다. 무엇이 나오는지 그대로 저장한다	AI 함정 #3
2	위 명세로 다시 시킨다. **1번 결과와 나란히** 놓고 무엇이 추가됐는지 적는다	질문이 답을 바꾼다
3	평균과 중앙값의 차이가 가장 큰 열을 찾는다. **왜 차이가 나는지** 그림으로 설명한다	치우침
4	데이터를 두 집단으로 나눌 기준 열 하나를 골라 **집단별로 따로** 평균·표준편차를 낸다	이봉 분포
5	3주차에 «평균 대치»로 만든 열이 있다면, 원본과 **표준편차를 비교**한다 (확장)	3주차 회수

1번과 2번의 답을 **둘 다 제출**합니다. 차이가 오늘의 성적입니다.

정리

한 장 요약

개념	핵심 한 줄
평균	무게중심이지 한가운데가 아니다. **극단값 하나에 통째로 끌려간다.**
중앙값	순서만 본다. 그래서 **버틴다.** 연봉·집값·대기시간은 중앙값으로 읽는다.
분산	편차를 제곱해서 평균낸 것. 부호를 지우려고 제곱한다. 단위가 점² 이라 읽을 수 없다.
표준편차	√분산. **«평균에서 대체로 얼마나 떨어져 있나»** 단위가 원래대로 돌아온다.
3주차 회수	평균 대치는 **편차 0인 가짜 값**을 대량 투입하는 일이다. 데이터가 실제보다 고르게 보인다.
분포의 모양	대칭에서만 평균≈중앙값. 꼬리가 끄는 쪽으로 평균이 간다.
이봉	봉우리가 둘이면 **두 집단이 섞인 것**이다. 요약할 게 아니라 쪼갠다.
앤스컴	여섯 숫자가 같아도 전혀 다른 데이터. **그려 보기 전에는 모른다.**
보고 규칙	평균 옆에 **표준편차와 n**. 평균과 중앙값이 다르면 그 차이가 곧 보고 내용.
AI 함정 #3	«요약해줘»는 평균만 부른다. **중앙값을 같이, 분포를 반드시 그리게** 시킨다.

다음 주

z-점수와 표준화

국어 80점과 수학 80점 중 어느 쪽이 잘한 걸까.
오늘 배운 **평균과 표준편차** 두 개만 있으면
단위가 다른 숫자들을 한 줄에 세울 수 있습니다.