WEEK 02

데이터의 종류와 수집 설계

정형·비정형 데이터, 그리고 설문·공공데이터·웹 수집

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

오늘의 질문

우리 학과 학생들은
통학에 시간을 얼마나 쓸까요?

이 질문에 답하려면
무엇부터 해야 할까요?

오늘 도착할 곳

세 가지를 가져갑니다

1 구조

표에는 문법이 있다. **행이 무엇인지** 정하는 것이 모든 분석의 출발점이다.

2 설계

데이터를 찾기 전에 **질문을 고정**한다. 순서를 바꾸면 분석이 아니라 해석이 된다.

3 함정

가진 데이터보다 **빠진 데이터**가 더 많은 것을 말한다.

PART I · 60분

데이터는 세상의 그림자다

측정되지 않은 것은, 분석에서는 존재하지 않는 것이 된다.

종류 · 1

세 가지 생김새

정형 (Structured)

행과 열이 정해진 표.
엑셀, CSV, 데이터베이스

바로 계산할 수 있다

반정형 (Semi-structured)

구조는 있는데 표는 아니다.
JSON, XML, 로그 파일

표로 펴야 계산할 수 있다

비정형 (Unstructured)

텍스트, 이미지, 음성, 영상
리뷰 글, 사진, 통화 녹음

숫자로 바꿔야 계산할 수 있다

세상의 데이터 중 **대부분은 비정형**입니다. 그런데 우리가 배울 분석은 거의 다 **정형**을 전제합니다. 그래서 **"표로 만드는 일"** 자체가 분석의 절반입니다.

구조 · 1 ★

표에는 문법이 있다

표에는 문법이 있다

열 = 변수 하나

행 = 관측 하나

학생ID	학과	학년	통학시간(분)
S001	디자인	2	35
S002	경영	1	72
S003	디자인	3	18

이 표에서 관측 단위(unit of observation)는 «학생 한 명» 이다.

관측 단위를 무엇으로 잡느냐가 수집 설계의 첫 결정이다.

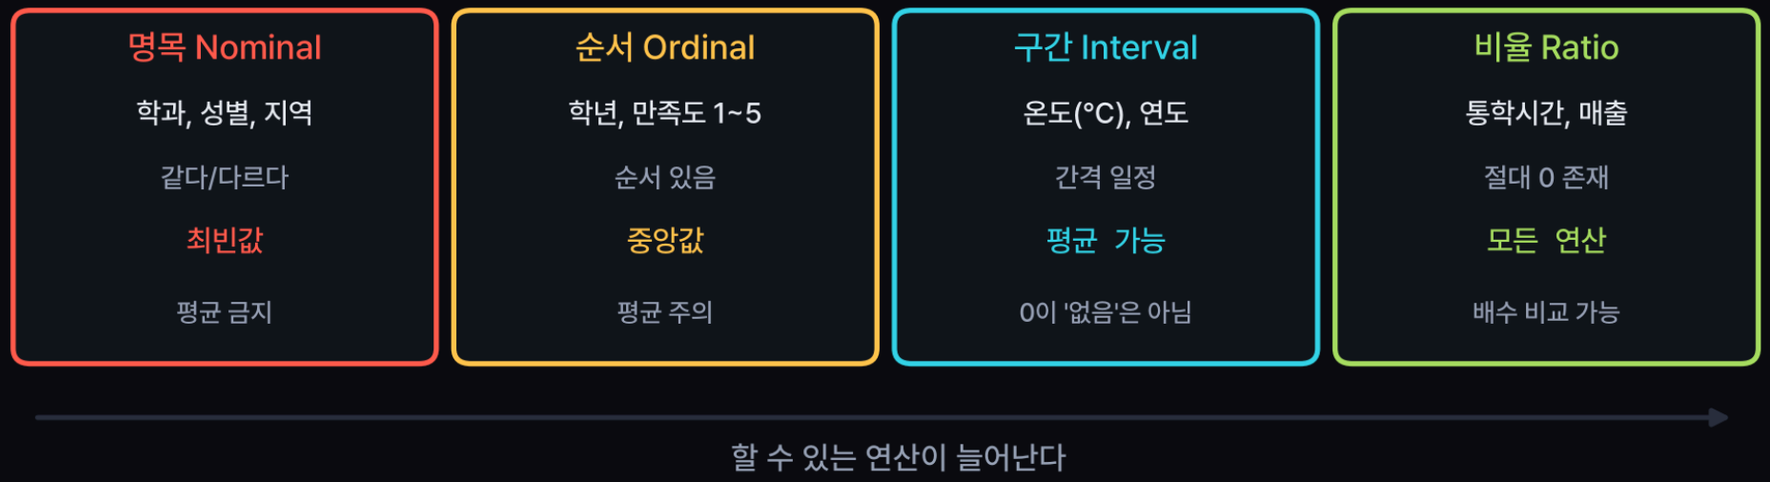
학생인가, 수업인가, 학기인가 — 여기서 갈리면 나중에 아무것도 맞지 않는다.

구조 · 2

평균을 낼 수 있는 값, 없는 값

변수의 네 가지 척도

«학과의 평균» 을 구하는 코드는 돌아간다. 다만 의미가 없을 뿐이다.



AI 는 척도를 보지 않고 계산한다. 척도를 판단하는 것은 사람의 일이다.

구조 · 3

기계가 읽을 수 있는 표

이런 표

학과	2024	2025	2026
디자인	41	45	52
경영	88	83	80

연도가 «열 이름» 이 되어 버렸다.

연도별로 그래프를 그리려면 매번 코드를 고쳐야 한다.

2027년 자료가 들어오면 구조가 또 바뀐다.

이렇게 바꾼다

학과	연도	인원
디자인	2024	41
디자인	2025	45
경영	2024	88
경영	2025	83

한 행 = 한 관측, 한 열 = 한 변수

행이 길어질 뿐 구조는 영원히 그대로다.

거의 모든 분석 도구가 이 모양을 기대한다.

정제의 목표는 «예뻐 보이는 표» 가 아니라 «기계가 읽을 수 있는 표» 다.

PART II · 30분

수집 설계

좋은 분석은 좋은 데이터에서 나오고,
좋은 데이터는 좋은 질문에서 나온다.

설계 · 1 ★

순서가 거꾸로다

수집 설계

데이터를 찾기 전에 질문을 먼저 고정한다



질문 없이 모은 데이터는 «분석» 이 아니라 «해석» 이 된다. 숫자를 보고 나서 이야기를 만들게 되기 때문이다.

설계 · 2

조작적 정의 — 말을 숫자로 바꾸기

"통학시간이 길다" 는 분석할 수 없습니다. 먼저 **재는 방법**을 정해야 합니다.

말	조작적 정의 (예시)	이 정의가 빠뜨리는 것
통학시간	집 문을 나서서 강의실 도착까지의 분	환승 대기, 도보 구간
인기 있는 강의	수강신청 마감까지 걸린 초	재수강, 필수과목 여부
위험한 교차로	연간 인명사고 건수	통행량이 많아서일 수도

> **완벽한 정의는 없습니다.** 중요한 것은 정의를 **먼저 적어두고**, 무엇이 빠지는지 **알고** 있는 것입니다.

설계 · 3

어디서 얻을 것인가

설문

내가 원하는 변수를 정확히 만들 수 있다.
질문이 답을 만든다 — 유도질문, 척도 설계에 결과가 좌우된다.

공공데이터

data.go.kr · KOSIS
규모가 크고 신뢰도가 높다.
내 질문에 딱 맞는 건 없다

웹 수집

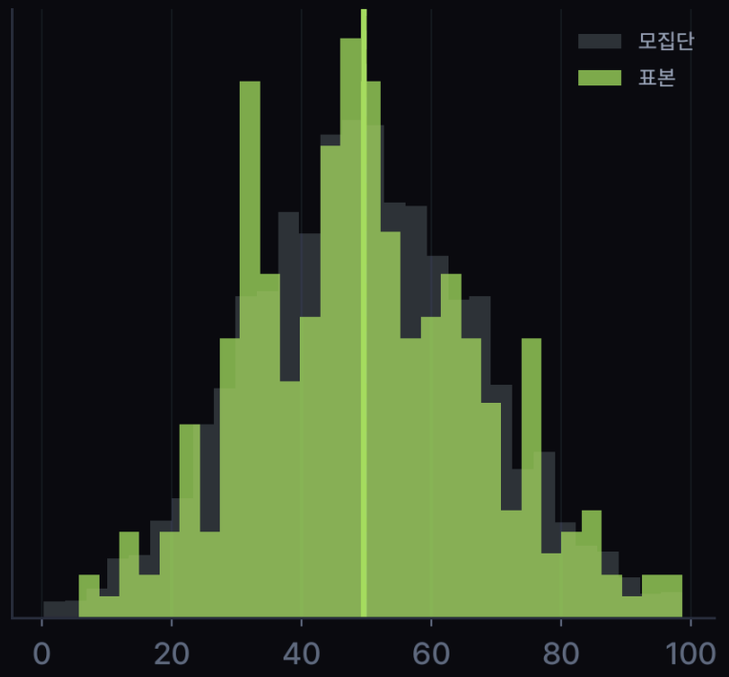
없는 데이터를 만들 수 있다.
이용약관·저작권·개인정보
기술보다 판단이 먼저다.

이번 학기 실습은 **공공데이터**를 씁니다. 실제로 지저분하고, 실제로 쓰이며, 무엇보다 **여러분이 마음대로 만들 수 없는 데이터**이기 때문입니다.

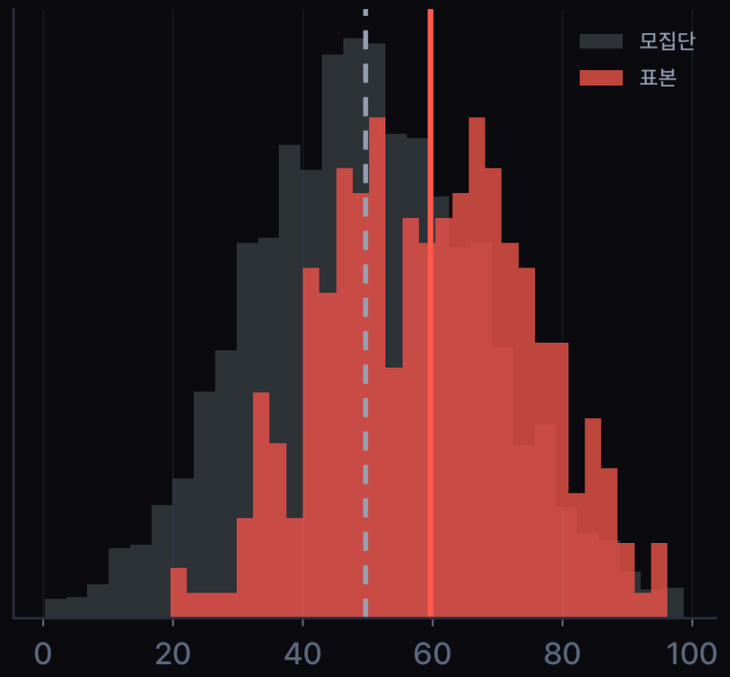
함정 · 1 ★

누구에게 물었는가

무작위로 뽑으면 표본평균 49.6



응답할 사람만 응답하면 표본평균 59.7

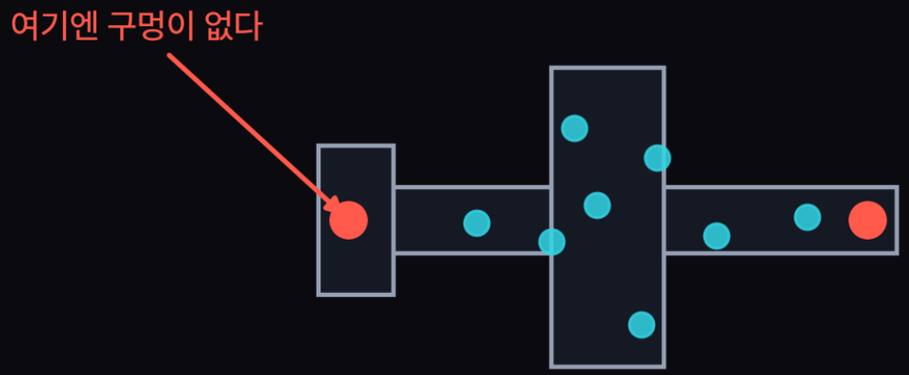


모집단 평균은 49.7 로 똑같다. 표본 크기를 300 에서 3만으로 늘려도 오른쪽은 틀린 채로 정밀해질 뿐이다.

함정 · 2 ★

돌아온 것만 보인다

생존자 편향



돌아온 비행기의 구멍 자리를 보강해야 할까?

아니다. 구멍이 없는 곳을 맞은 비행기는 «돌아오지 못했다».

우리가 가진 데이터는 살아남은 것들뿐이다.

이 데이터에 누가 빠져 있는가? — 분석 전에 반드시 묻는 질문.

설계 · 4

분석 전에 반드시 묻는 질문

> **이 데이터에는 누가 빠져 있는가?**

배달앱 리뷰 데이터

아주 좋았거나 아주 나빴던 사람만 씁니다. **보통이었던 사람**이 통째로 빠져 있습니다.

수업 만족도 설문

중도 포기한 학생은 응답하지 않습니다. **가장 불만족한 집단**이 빠져 있습니다.

표본 크기를 아무리 늘려도 이 문제는 해결되지 않습니다. **틀린 채로 정밀해질 뿐입니다.**

PART III · 50분

바이브코딩 실습

코드는 AI가 씁니다. 여러분은 **무엇을 요구할지**와 **무엇이 틀렸는지**를 판단합니다.

실습 · 1

이 수업의 실습은 3단 루프다

1 질문

무엇을 알고 싶은지 한 문장으로 적는다.

2 명세

AI에게 **정확한 용어**로 요구한다.

3 검증

결과가 **정말 그런가**를 원본으로 되짚는다.

프로그래밍을 몰라도 됩니다. 다만 **무엇이 이상한지 알아보는 눈**은 있어야 합니다. 그것이 이 수업에서 기르는 것입니다.

AI 함정 #1

AI는 없는 데이터를 만들어낸다

이렇게 물어보면

"부산 지역 대학생 통학시간
공공데이터 링크 좀 줘"

↓ AI가 주는 것

data.go.kr/dataset/3082...
「부산광역시 대학생
통학실태조사」 (2024)

그럴듯하지만 존재하지 않는다

반드시 해야 할 것

- 링크를 **직접 열어본다**
- 파일을 **실제로 내려받는다**
- 행 수와 열 이름을 **눈으로 본다**
- 조사 기관·연도·조사 대상을 확인한다

"AI가 알려줬다"는 출처가 아닙니다

실습 · 2

명세는 네 칸이다

```
[목표]
내려받은 CSV 파일의 구조를 파악한다.

[제약]
- 파일을 임의로 수정하지 말 것
- 결측치를 채우거나 행을 지우지 말 것 (이번 주는 «보기»만)

[검증 조건]
- 출력된 행 수가 원본 파일의 줄 수와 일치할 것
- 각 열의 자료형과 결측 개수를 표로 보여줄 것

[비목표]
- 그래프, 통계 분석은 하지 말 것
```

> [제약]에 **"하지 말 것"**을 적는 이유 — AI는 시키지 않아도 친절하게 정제해 버립니다. 그것이 다음 주의 주제입니다.

실습 · 3

오늘 할 것 — 90분

#	할 일	확인할 것
1	관심 주제를 정하고 **질문 한 문장**과 **조작적 정의**를 적는다	수집 설계
2	AI에게 관련 공공데이터를 물어보고, **링크를 하나씩 직접 열어** 진짜인지 확인한다	AI 함정 #1
3	data.go.kr 에서 실제로 CSV 를 내려받는다	실물 확보
4	위 명세로 AI에게 **구조만** 파악시킨다 — 행 수, 열 이름, 자료형, 결측 개수	표의 문법
5	그 데이터로 내 질문에 **답할 수 있는지** 판단한다. 없으면 무엇이 부족한지 적는다	설계 검증

5번에서 "답할 수 없다"는 결론이 나와도 괜찮습니다. **그것을 지금 아는 것이 이 실습의 목적**입니다.

정 리

한 장 요약

개념	핵심 한 줄
정형·비정형	세상은 비정형인데 분석은 정형을 요구한다. 표로 만드는 게 절반이다.
관측 단위	**한 행이 무엇인지** 정하는 것이 첫 결정. 여기서 틀리면 전부 어긋난다.
척도	«학과의 평균»은 코드가 돌아가도 의미가 없다. 판단은 사람이 한다.
tidy	한 행 = 한 관측, 한 열 = 한 변수.
수집 설계	**질문 → 조작적 정의 → 변수 → 출처.** 거꾸로 가면 해석이 된다.
편향	**이 데이터에 누가 빠져 있는가.** 표본을 늘려도 해결되지 않는다.
AI 함정 #1	AI는 없는 데이터셋을 그럴듯하게 지어낸다. **반드시 직접 열어본다.**

다음 주

데이터 정제

오늘 내려받은 그 파일을 열어봅니다.
빈칸, 중복, 깨진 글자, "미상" — 그리고 그것을 어떻게 다룰지가 **결론을 바꾸는** 이야기.