WEEK 03

데이터 정제와 전처리

결측치·중복·오류 처리, 그리고 바이브코딩으로 데이터 다루기

데이터리터러시의이해 SF1101084 · AI융합교육원

조성호 · 2026학년도 2학기

오늘의 질문

두 팀이 같은 데이터로 같은 질문에 답했습니다.

그런데 결론이 정반대입니다. 둘 중 누가 조작한 걸까요?

오늘 도착할 곳

세 가지를 가져갑니다

1 기술

빈칸·중복·깨진 글자·문자가 된 숫자를 **알아보고 고친다**.

2 판단

정제는 기계적인 청소가 아니라 **결론을 바꾸는 결정**이다.

3 함정

AI는 시키지 않아도 **말없이 채우고 지운다**.

PART I · 60분

현실의 데이터는 더럽다

분석 시간의 절반 이상이 여기에 쓰인다.
그리고 이 절반이 결과의 신뢰도를 결정한다.

정제 · 1 ★

다섯 줄에 다섯 가지 문제

현실의 데이터

지역	인구	면적	조사일
서울특별시	9,411,440	605.2	2026-01-01
서울시	9411440	605.2	2026.01.01
부산	-	770.1	2026-01-01
대구	2,374,960	미상	
ë¶€ì‚°	3,349,016	770.1	26/1/1

← 같은 도시가 두 이름 — 중복인가 다른 관측인가

← 천 단위 쉼표 → 숫자가 아니라 «문자»

← 빈칸을 «-» 로 적었다

← «미상» 과 빈칸 — 뜻이 같은가 다른가

← 인코딩이 깨졌다 (CP949 를 UTF-8 로 읽음)

네 줄 다섯 칸짜리 표에 이미 다섯 가지 문제가 있다.

공공데이터를 내려받으면 거의 항상 이 상태다. 분석 시간의 절반 이상은 여기에 쓰인다.

정제 · 2

숫자로 보이지만 숫자가 아니다

화면에 보이는 것	실제 자료형	그래서 생기는 일
`9,411,440`	문자	합계를 내면 오류나 이상한 값
`12%`	문자	0.12 인지 12 인지 모른 채 계산
`2026.01.01`	문자	날짜 정렬이 사전순으로 됨
`001`	숫자로 읽히면	앞의 0 이 사라져 `1` 이 됨 — 우편번호·학번 사고

엑셀로 CSV 를 열지 마세요. 여는 순간 학번의 앞 0 이 지워지고, 날짜가 제멋대로 바뀝니다. 그리고 그 상태로 저장됩니다.

정제 · 3

인코딩 — 한국 공공데이터의 고전

```
부산  →  ë¶€ì‚°
서울  →  ¼ïï
```

글자가 깨졌다면 **데이터가 망가진 것이 아니라 읽는 방식이 틀린 것**입니다.

왜 생기나

국내 공공기관 파일은 아직 **CP949(EUC-KR)** 로 저장된 경우가 많은데, 요즘 도구는 **UTF-8** 로 읽으려 합니다.

> AI에게 **"인코딩을 cp949 로 지정해서 읽어줘"** 라고 말할 수 있으면 끝나는 문제입니다. 몰라서 30분을 헤맵니다.

정제 · 4 ★

빈칸에도 이유가 있다

결측치 — 세 가지 이유

«비었다» 는 사실보다 «왜 비었나» 가 중요하다

우연히 비었다

설문지 한 장이 커피에 젖었다

지워도 대체로 안전하다

다른 변수 때문에 비었다

고학년일수록 소득 문항을 건너뛴다

학년을 알면 메울 수 있다

값 자체가 이유다

소득이 높은 사람이 소득을 안 적는다

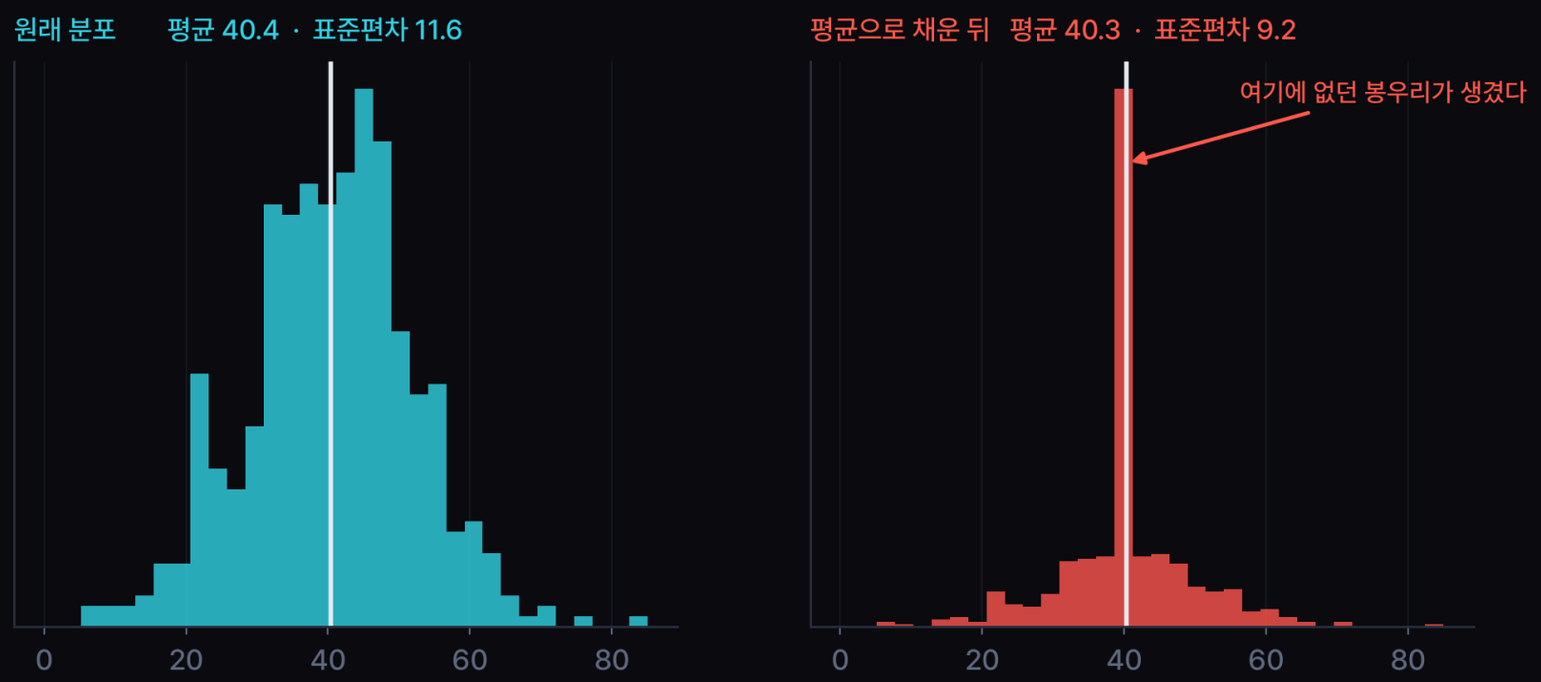
지우면 결론이 통째로 틀어진다

AI 에게 «결측치 처리해줘» 라고만 하면 세 경우를 구분하지 않고 똑같이 처리한다.

세 번째를 두 번째처럼 다루면, 코드는 멀쩡히 돌아가고 결론만 조용히 틀린다.

정제 · 5 ★

평균으로 채우면 벌어지는 일



평균은 지켜졌지만 «흩어진 정도» 가 줄었다. 이 데이터로 검정을 돌리면 없는 차이가 있다고 나온다.

AI 가 가장 자주 고르는 기본 처리가 바로 이것이다 — 11주차 p값과 직결된다.

정제 · 5 ★

결측 비율을 올려 보세요

인터랙티브 데모

이 자리에는 직접 조작하는 3D 데모가 있습니다.
HTML 슬라이드를 브라우저로 열어 확인하세요.

정제 · 6

중복과 이상치 — 지울 것인가

중복처럼 보이는 것

같은 사람이 **두 번 응답**했다 → 지운다
같은 사람이 **두 학기 수강**했다 → 지우면 안 된다

완전히 같은 행인지, 키만 같은지 먼저 본다.

이상치처럼 보이는 것

통학시간 **480분**
· 입력 오류인가?
· 정말 제주에서 통학하는가?

원본을 확인하기 전에는 지울 수 없다.

> 이상치를 **찾는** 방법은 5주차(z-점수)에서 배웁니다. 오늘은 **찾았을 때 무엇을 할 것인가**가 주제입니다.

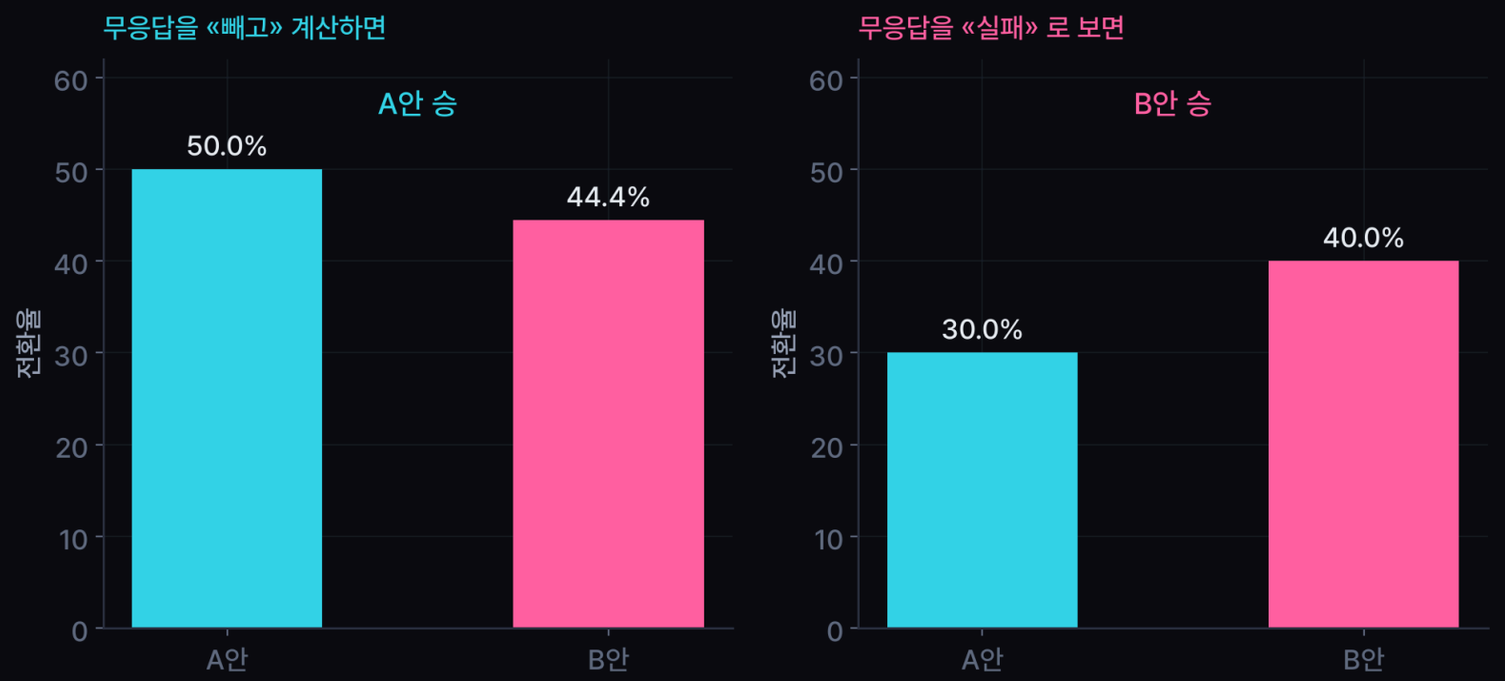
PART II · 30분

정제는 판단이다

청소가 아니다. 결정이다. 그리고 결정은 기록해야 한다.

판 단 · 1 ★

같은 데이터, 다른 결론



숫자는 하나도 조작하지 않았다. 정제 규칙 한 줄이 승자를 바꿨을 뿐이다.

그래서 «어떻게 정제했는가» 를 적어두지 않은 분석은 검증할 수 없다.

판단 · 2

그래서 무엇을 해야 하나

> **정제 규칙을 분석 전에 정하고,**
> **그대로 적어둔다.**

결과를 본 뒤에 정제 규칙을 바꾸면, 그것은 분석이 아니라 **원하는 답 찾기**가 됩니다.

이 문제는 10~11주차 A/B 테스트에서 다시, 훨씬 심각하게 나타납니다.

판단 · 3

정제 로그

정제 로그

무엇을	왜	어떻게	영향받은 행
'-', '미상' → 빈칸	결측 표기가 세 가지	전부 NA 로 통일	412
인구 열 문자→숫자	쉼표 때문에 문자였음	쉼표 제거 후 정수	1,204
'서울시'→'서울특별시'	같은 지역 다른 표기	행정표준코드 기준	37
통학 480분 유지	제주 통학, 오류 아님	제거하지 않음	2

네 번째 줄이 핵심이다 — «지우지 않기로 한 결정» 도 기록한다.

정제 로그가 있으면 결론이 의심받을 때 어느 결정 때문인지 되짚을 수 있다.

없으면 «데이터가 그렇게 나왔다» 는 말밖에 할 수 없다.

PART III · 50분

바이브코딩 실습

AI 에게 정제를 시키되, **무엇을 했는지** 전부 말하게 한다.

AI 함정 #2

AI는 친절해서 위험하다

이렇게 물어보면

"이 데이터 정제해줘"

↓ AI가 조용히 하는 일

- 결측치를 평균으로 채움
- 중복처럼 보이는 행 삭제
- 이상치를 자동으로 제거
- 자료형을 알아서 변환

보고는 «정제 완료!» 한 줄

이렇게 물어야 한다

"어떤 문제가 있는지 **보고만** 해줘.
아직 아무것도 고치지 마."

↓ 그 다음

- 문제를 내가 본다
- 처리 방법을 내가 정한다
- **정한 것만** 시킨다
- 처리 전후 행 수를 비교한다

실습 · 1

이번 주 명세

```
[목표]
지난주 내려받은 CSV 의 문제를 «진단만» 한다.

[제약]
- 아무것도 고치지 말 것. 채우지도, 지우지도 말 것
- 원본 파일을 덮어쓰지 말 것

[검증 조건]
- 열별로: 자료형 / 결측 개수 / 고유값 개수 를 표로
- 결측이 있는 열은 «어떤 값으로 표시되어 있는지» 실제 예시를 보여줄 것
  (빈칸인지, '-' 인지, '미상' 인지)
- 완전히 동일한 행이 몇 개인지
- 처리 전 행 수를 맨 위에 출력할 것

[비목표]
- 정제, 그래프, 통계 분석
```

> [제약]의 첫 줄이 이번 주의 전부입니다. **진단과 처리를 분리하는 것**이 데이터를 다루는 사람의 기본기입니다.

실습 · 2

오늘 할 것 — 90분

#	할 일	확인할 것
1	위 명세로 **진단만** 시킨다. AI가 몰래 고쳤는지 행 수로 확인한다	AI 함정 #2
2	결측이 있는 열 하나를 골라 **왜 비었을지** 세 가지 이유 중 무엇인지 판단한다	결측의 이유
3	그 열을 **① 행 삭제** 와 **② 평균 대치** 두 방법으로 각각 처리하고, 평균과 표준편차를 비교한다	정제가 숫자를 바꾼다
4	내가 내린 결정을 **정제 로그**로 적는다 — 지우지 않기로 한 결정도 포함	재현 가능성
5	인코딩이 깨진 파일을 일부러 만들어보고 `cp949` 로 되살린다 (확장)	인코딩

3번에서 **두 방법의 숫자가 다르게 나오는 것**을 직접 보는 것이 오늘의 핵심입니다.

정 리

한 장 요약

개념	핵심 한 줄
자료형	쉼표·%·앞의 0 — 숫자로 보여도 문자다. **엑셀로 CSV 를 열지 마라.**
인코딩	글자가 깨진 건 데이터가 망가진 게 아니라 읽는 방식이 틀린 것. `cp949`
결측	«비었다»보다 **«왜 비었나»**가 중요하다. 세 경우를 같게 다루면 결론이 틀어진다.
평균 대치	평균은 지켜지고 **표준편차만 줄어든다.** 없는 차이가 유의하게 나온다.
중복·이상치	지우기 전에 **원본을 확인**한다. 480분은 오류일 수도, 제주 통학일 수도.
정제는 판단	규칙 한 줄이 **승자를 바꾼다.** 결과를 보고 규칙을 바꾸면 «답 찾기»다.
정제 로그	적어두지 않은 분석은 **검증할 수 없다.** 지우지 않기로 한 결정도 기록한다.
AI 함정 #2	AI는 시키지 않아도 채우고 지운다. **진단과 처리를 분리하라.**

다음 주

기술통계 기초

평균·중앙값·분산·표준편차.
오늘 본 «표준편차가 줄었다» 는 말이
정확히 무슨 뜻인지 배웁니다.